

Prédire le départ des clients (Telco)

Aya Mhiri, I13 IA, ENSI · Challenge 1 Data Mining · Cas 13 : télécom, attrition client

1. Problème métier

Identifier les clients qui risquent de résilier pour leur proposer une action de rétention avant leur départ. Hypothèse de travail : perdre un client coûte plus cher qu'une offre de rétention envoyée à tort, donc on préfère détecter la plupart des départs quitte à accepter des fausses alertes.

2. Données

7 043 clients, 20 variables, 26,5 % de départs. Points traités : **TotalCharges** (11 valeurs vides, clients d'ancienneté 0), classes déséquilibrées (73/27), forte redondance tenure / TotalCharges (corrélation 0,83). Le taux de départ varie beaucoup selon le contrat (43 % en mensuel, 11 % à 1 an, 3 % à 2 ans), la fibre optique (42 %) et le chèque électronique (45 %) ; le genre n'a aucun effet (27 % contre 26 %).



3. Méthode

Split stratifié 80/20, imputation, OneHot et normalisation ajustés sur le train, 5 modèles, RandomizedSearchCV (critère AUC, validation croisée), pondération des classes, seuil de décision réglable. Application Streamlit et API FastAPI.

4. Meilleur modèle et résultats

Modèle (seuil 0,5)	AUC	PR-AUC	Rappel	Précision	F1
XGBoost	0,846	0,658	0,805	0,513	0,626
Random Forest	0,845	0,657	0,797	0,522	0,631
Logistic Regression	0,841	0,627	0,781	0,505	0,613
Decision Tree	0,836	0,622	0,805	0,524	0,635
KNN	0,830	0,623	0,570	0,607	0,588
XGBoost, seuil retenu 0,6	0,846	0,658	0,735	0,572	0,643

Seuil retenu : 0,6 (maximise le F1). Par rapport à 0,5, on obtient 80 fausses alertes de moins (206 au lieu de 286) au prix de 26 départs détectés en moins (99 ratés au lieu de 73). Si l'offre de rétention est peu coûteuse, un seuil plus bas reste défendable ; le bon seuil dépend des coûts réels.



5. Compromis performance / simplicité

XGBoost est le meilleur, mais il ne dépasse la régression logistique que de **0,005 d'AUC** (0,846 contre 0,841). Recommandation : la régression logistique, plus simple, plus rapide et plus facile à expliquer, suffit pour un premier déploiement ; XGBoost se justifie si ce petit gain pèse sur un grand nombre de clients.

6. Recommandations et limites

Cibler en priorité les clients en contrat mensuel, de faible ancienneté, en fibre optique ou payant par chèque électronique, et pousser le support technique et la sécurité en ligne, associés à moins de départs. Limites : un seul jeu de données, un seul découpage train/test, une association n'est pas une causalité, seuil dépendant des coûts réels non connus ici.