Prédire et expliquer le départ des clients (Telco Churn)

Challenge 1 · Classification explicable · Data Mining ENSI 2026-2027 · Aya MHIRI, II3 IA

1. Problème métier

Un opérateur télécom perd des clients chaque mois. Recruter coûte plus cher que fidéliser : il faut **repérer à l'avance** les clients prêts à partir, pour leur proposer une action ciblée, et savoir **pourquoi** le modèle les signale afin de choisir la bonne action.

2. Données

- Telco Customer Churn : **7043 clients**, 20 variables (profil, services souscrits, contrat, facturation), cible : parti ou resté.
- **26,5 % de départs** (classes 73/27) : on suit l'AUC, la PR-AUC, le rappel et le F1, pas seulement l'exactitude.
- **TotalCharges** est en texte avec 11 valeurs vides cachées (clients de 0 mois) : converties et imputées.
- Départs : contrat mensuel **42,7 %** contre 2,8 % à deux ans ; fibre 41,9 % ; chèque électronique 45,3 % ; sans support technique 41,6 % contre 15,2 %.
- Préparation ajustée sur le train seul (aucune fuite), split stratifié, validation croisée à 3 plis, déséquilibre géré par pondération des classes.

3. Meilleur modèle

XGBoost (100 arbres, profondeur 3, taux d'apprentissage 0,05) : **AUC 0,846**, PR-AUC 0,658. À seuil 0,5 il retrouve 80 % des départs (rappel 0,805) mais avec 51 % de précision. Le **seuil 0,6** équilibre mieux : précision 0,572, rappel 0,735, **F1 0,643**.
Les cinq modèles sont très proches (AUC de 0,830 à 0,846). La **régression logistique, lisible, ne perd que 0,005 d'AUC**.

4. Recommandations

- **Contrats longs** : proposer un engagement d'un an à prix réduit aux clients en contrat mensuel signalés à risque.
- **Nouveaux clients** : suivi renforcé les 6 premiers mois, période où le risque est maximal.
- **Support et sécurité** : offrir un essai du support technique et de la sécurité en ligne aux clients à risque.
- **Fibre optique et chèque électronique** : enquêter sur la qualité de service et inciter au prélèvement automatique.
- **Seuil** : le fixer selon le coût d'une offre inutile par rapport à celui d'un départ raté (seuil 0,6 par défaut conseillé).

Résultats des 5 modèles

Modèle	AUC	PR-AUC	Rappel	F1
XGBoost	**0,846**	**0,658**	**0,805**	**0,626**
Random Forest	0,845	0,657	0,797	0,631
Rég. logistique	0,841	0,627	0,781	0,613
Arbre	0,836	0,622	0,805	0,635
KNN	0,830	0,623	0,570	0,588

5. Explications clés (SHAP, XGBoost)

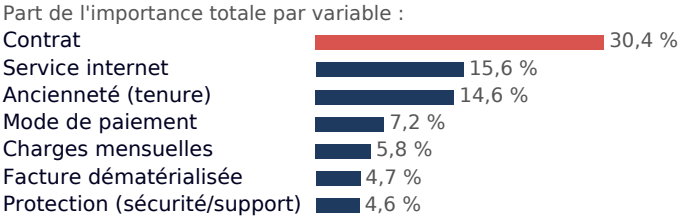

- **Risque en hausse** : contrat mensuel, fibre optique, chèque électronique, moins de 6 mois d'ancienneté (contribution SHAP moyenne +0,55 contre −0,53 après 4 ans).
- **Risque en baisse** : contrat de 1 ou 2 ans, pas d'internet, services de sécurité et de support, forte ancienneté.
- **Cohérence SHAP / LIME** sur un client parti (risque 61 %) : 4 variables sur 5 en commun dans le top 5 et 100 % d'accord sur le sens des effets. LIME donne des poids plus faibles (R^2 local 0,68).
- **Importance par permutation** : le contrat arrive en tête pour XGBoost, le service internet pour la régression logistique ; service internet et ancienneté figurent dans le top 3 des deux modèles.

6. Équité

- Genre, senior, couple et personnes à charge ne portent que **2,4 %** de l'importance SHAP.
- Écart de taux de prédictions positives : genre **0,015** ; personnes à charge 0,276 ; couple 0,254 ; senior 0,302. Ces écarts suivent des taux réels de départ différents (senior 44 % contre 23 %), mais la facture et le mode de paiement peuvent jouer un rôle de variable substitut : à surveiller avant tout usage automatique.

7. Limites

- Association et non causalité : une explication décrit le modèle, pas la cause du départ.
- Un seul jeu de données et un seul découpage ; SHAP et LIME sont des approximations (LIME varie d'un tirage à l'autre).
- Les poids de la régression logistique sont délicats à lire (charges mensuelles, services et fibre sont liés entre eux).
- Application de démonstration : sessions en mémoire, API gratuite qui s'endort.

Code et application : github.com/Aya-MHIRI/telco-churn-xai- · Résultats sur 1409 clients de test, seuil 0,5 sauf mention contraire.